

UNIVERSIDAD INTERNACIONAL DE LA RIOJA (UNIR)

Máster Universitario en Análisis y Visualización de Datos Masivos

ASIGNATURA:

Bases de Datos para el Big Data

ACTIVIDAD 1:

Limpieza de Datos

Presentado por:

GARI BUSTOS JOSEPH DAVID

noviembre de 2025

Tabla de Contenido

1. DESCRIPCIÓN DE LOS PROBLEMAS DETECTADOS	3
1.2. Datos no estructurados y suciedad en direcciones	3
1.3. Esquema de metadatos incorrecto (Headers como preguntas)	4
1.4. Redundancia de Información Temporal	5
1.5. Inconsistencia en valores categóricos	5
1.6. Duplicidad Semántica	6
2. PROPUESTA DE FORMATO JSON	6
2.1. Estrategia de conversión y optimización.....	6
3. METODOLOGÍA DE LIMPIEZA.....	7
Fase 1: Diagnóstico y Perfilado Dimensional (Profiling).....	7
Fase 2: Saneamiento Estructural y Reducción de Ruido.....	8
Fase 3: Normalización Semántica Avanzada (Algorítmica)	8
Fase 4: Estrategia de Reconstrucción Constructiva (Coalescencia)	8
4. MEJORAS EN EL CONJUNTO DE DATOS.....	9

1. DESCRIPCIÓN DE LOS PROBLEMAS DETECTADOS

Para la realización de esta actividad se han seleccionado y analizado tres conjuntos de datos de naturaleza heterogénea: un registro de **Incidentes Policiales** (data_act_01.csv), un catálogo de **Instalaciones Deportivas** (areas_actividades_deportivas.csv) y una **Encuesta de Visitantes** (Microdatos 2024.csv).

A continuación, se detallan los seis problemas estructurales y de contenido más relevantes identificados durante el proceso de perfilado de datos, siguiendo el esquema de detección, justificación y solución aplicada.

1.1. Dispersión y falta de estandarización en categorías

- **Fuente:** Dataset 1 (Incidentes Policiales).
- **Descripción del problema:** La columna OriginalCrimeTypeName presentaba una alta cardinalidad con cientos de valores únicos para describir tipologías criminales similares. Se encontraron variaciones semánticas (ej: "Assault", "Battery", "Strongarm" para violencia) y códigos administrativos residuales ("X", "Jo", "Rep") que no aportan información descriptiva.
- **Detección:** Mediante el uso de facetas de texto (*Text Facet*) en OpenRefine, se observó una distribución de "cola larga" (*long tail*), donde la mayoría de las categorías tenían menos de 5 registros y muchas eran variaciones ortográficas de un mismo concepto.
- **Impacto:** Esta dispersión impide el análisis estadístico. No es posible agregar datos para responder preguntas básicas de negocio (ej: "¿Total de robos?") si los datos están fragmentados en 50 subetiquetas distintas.
- **Ejemplo:** Valores originales dispersos: "Agg Assault / Adw Dv", "Battery", "Weapon In Progress".
- **Solución:** Se implementó un script en lenguaje **Jython** utilizando **Expresiones Regulares (Regex)** para agrupar estas variaciones en macro-categorías estandarizadas.

1.2. Datos no estructurados y suciedad en direcciones

- **Fuente:** Dataset 2 (Áreas Deportivas).
- **Descripción del problema:** La columna DIRECCION_AUX contenía información no estructurada ("suciedad"), mezclando la dirección física real con prefijos redundantes, palabras duplicadas y códigos internos de la base de datos de origen.
- **Detección:** Inspección visual y facetado. Se identificaron patrones repetitivos de error en la entrada de datos, como la repetición de tipos de vía y colas de texto técnico.

- **Impacto:** Afecta gravemente a la calidad del dato y la interoperabilidad. Un servicio de geolocalización (como Google Maps API) fallaría al intentar interpretar cadenas con ruido técnico.
- **Ejemplo:** Valor original: "Avda · AVENIDA BRASIL N°13 , ASCENDIENTE 1: 062 ·". Valor con duplicidad: "Parque · PARQUE PARQUE CIUDAD DE LOS ANGELES".
- **Solución:** Se aplicó una transformación compleja utilizando el lenguaje **GREL** (Google Refine Expression Language) para limpiar prefijos, normalizar duplicados y truncar la información técnica residual.

1.3. Esquema de metadatos incorrecto (Headers como preguntas)

- **Fuente:** Dataset 3 (Encuesta Visitantes).
- **Descripción del problema:** Los nombres de las columnas (cabeceras del CSV) correspondían a las preguntas literales formuladas en la encuesta en lenguaje natural, incluyendo caracteres especiales y espacios, en lugar de utilizar identificadores técnicos.
- **Detección:** Durante la ingesta de datos, se detectaron cabeceras con una longitud excesiva (superiores a 100 caracteres) y caracteres no estándar (¿, ?, tildes), lo cual es una mala práctica en diseño de bases de datos.
- **Impacto y Justificación:**
 - **Ineficiencia en Almacenamiento:** En formatos autodescriptivos como JSON, la clave (nombre de columna) se repite por cada registro. Mantener la pregunta completa como clave infla artificialmente el tamaño del archivo, aumentando el consumo de ancho de banda y almacenamiento sin aportar valor.
 - **Interoperabilidad:** El uso de espacios y caracteres especiales en los nombres de columna suele generar errores de sintaxis en motores SQL (SELECT "1_¿Qué..." vs SELECT museo) y complica el mapeo en herramientas de visualización o librerías de programación (Pandas/Python).
- **Solución:** Se ejecutó una normalización del esquema de metadatos, renombrando las columnas a formato snake_case (identificadores cortos, en minúsculas y sin espacios). Se estableció el siguiente diccionario de mapeo:

Columna (Pregunta)	Original	Nuevo Identificador Técnico	Descripción
1_¿Qué museo acabas de visitar?	museo_acabas_de_visitar?	museo_visitado	ID/Nombre del museo
2_La recepción y atención al público	val_atencion		Valoración (0-10)
4_El confort, el orden y la limpieza...	val_confort		Valoración Infraestructura
6_Teniendo en cuenta toda su exp...	val_global		Valoración General
8_¿Cuál es su grupo de edad?	rango_edad		Demografía
9_¿Cuál es su sexo?	sexo		Demografía

1.4. Redundancia de Información Temporal

- **Fuente:** Dataset 1 (Incidentes Policiales).
- **Descripción del problema:** Violación de la normalización de datos. La información temporal se encontraba fragmentada y duplicada en tres columnas distintas: `OffenseDate` (fecha), `CallTime` (hora) y `CallDateTime` (fecha y hora combinadas).
- **Detección:** Comparando las columnas, se verificó que `CallDateTime` contenía la concatenación exacta de las otras dos, haciendo que estas fueran redundantes.
- **Impacto:** Desperdicia espacio de almacenamiento y crea riesgos de integridad de datos (anomalías de actualización), donde una modificación en la fecha no se refleje automáticamente en el campo combinado.
- **Ejemplo:**
 - `OffenseDate`: "2016-03-30"
 - `CallTime`: "18:42"
 - `CallDateTime`: "2016-03-30T18:42:00"
- **Solución:** Eliminación de las columnas redundantes (`OffenseDate`, `CallTime`) y transformación de `CallDateTime` a formato estándar de fecha (ISO 8601) para servir como fuente única de verdad.

1.5. Inconsistencia en valores categóricos

- **Fuente:** Dataset 3 (Encuesta Visitantes).

- **Descripción del problema:** Falta de vocabulario controlado. El mismo concepto o entidad estaba representado con diferentes cadenas de texto, generando ambigüedad en la variable "Sexo".
- **Detección:** Al realizar un *Text Facet* en la columna correspondiente, se encontraron clústeres semánticos separados para conceptos idénticos.
- **Impacto:** Falsea los resultados de cualquier agregación o conteo. Un sistema informático considera "Hombre" y "Masculino" como dos entidades distintas, dividiendo las estadísticas erróneamente.
- **Ejemplo:** Valores mezclados en la misma columna: "Hombre", "Masculino", "Mujer", "Femenino".
- **Solución:** Estandarización masiva mediante la función *Cluster and Edit* y ediciones manuales para unificar los términos a un estándar binario o controlado: "Masculino" y "Femenino".

1.6. Duplicidad Semántica

- **Fuente:** Dataset 2 (Áreas Deportivas).
- **Descripción del problema:** Existencia de columnas redundantes (TIPO y DESC_CLASIFICACION) que almacenaban la misma información de negocio con variaciones mínimas en la nomenclatura.
- **Detección:** Comparación visual de columnas adyacentes donde se observó una correlación del 100% entre los valores.
- **Impacto:** Aumenta el "ruido" en el dataset sin aportar nueva dimensionalidad analítica.
- **Ejemplo:** Columna TIPO: "MAYORES" vs Columna DESC_CLASIFICACION: "Área de mayores".
- **Solución:** Eliminación de la columna TIPO por ser menos descriptiva y presentar formatos menos amigables para el usuario final.

2. PROPUESTA DE FORMATO JSON

Como entregable final de la actividad, se han generado tres ficheros JSON GARI_BUSTOS_JOSEPH_actividad_1_DATASET1.json, GARI_BUSTOS_JOSEPH_actividad_1_DATASET2.json, GARI_BUSTOS_JOSEPH_actividad_1_DATASET3.json), uno por cada dataset procesado.

2.1. Estrategia de conversión y optimización

El paso de CSV (formato tabular) a JSON (formato documental jerárquico) se ha aprovechado para realizar una limpieza estructural profunda:

1. **Eliminación de campos redundantes:** Tal como se detalló en la sección anterior, columnas como State, AgencyId (Dataset 1) o TIPO (Dataset 2) se eliminaron antes de la conversión. Esto reduce significativamente el peso del archivo JSON, ya que, en una base de datos NoSQL, cada clave se almacena en cada documento.
2. **Consolidación de objetos (Caso Dataset 2):** En el dataset de Áreas Deportivas, se reconstruyó la dirección física. En lugar de exportar fragmentos sucios (NOM_VIA, NUM_VIA), se exporta una única clave DIRECCION_FINAL limpia y validada.
3. **Optimización de claves (Caso Dataset 3):** Se renombraron las claves de preguntas largas a identificadores cortos (museo_visitado), lo que facilita la ingesta de datos en sistemas Big Data.

3. METODOLOGÍA DE LIMPIEZA

Para abordar la limpieza de estos datasets heterogéneos, se ha diseñado e implementado una metodología iterativa denominada "**Refinamiento Progresivo**". Esta aproximación no se limita a corregir errores puntuales, sino que aplica algoritmos de transformación replicables para elevar la calidad del dato desde su estructura hasta su semántica.

El proceso se divide en cuatro fases universales:

Fase 1: Diagnóstico y Perfilado Dimensional (Profiling)

Antes de cualquier manipulación, se somete el dataset a un análisis de sus dimensiones de calidad:

1. **Análisis de Cardinalidad:** Uso de *Text Facets* para detectar "colas largas" (*long tails*) en variables categóricas (como se detectó en los cientos de tipos de crímenes dispersos).
2. **Detección de Patrones Nulos:** Identificación de columnas con alta *sparseness* (escasez de datos), como la columna Range o contact_id, candidatas inmediatas a eliminación para reducir ruido.
3. **Auditoría de Tipos:** Verificación de que las marcas temporales y coordenadas numéricas no estén enmascaradas como texto plano.

Fase 2: Saneamiento Estructural y Reducción de Ruido

Esta fase se centra en la "forma" de los datos, eliminando lo que no aporta valor analítico (Reducción de Dimensionalidad):

1. **Poda de Atributos (Pruning):** Eliminación sistemática de columnas redundantes (ej: OffenseDate vs CallDateTime), columnas constantes (varianza cero) y metadatos técnicos del sistema origen.
2. **Normalización de Esquema:** Renombrado de atributos utilizando la convención *snake_case* para desacoplar el modelo de datos de las preguntas de negocio (ej: transformar la pregunta completa de la encuesta en un ID técnico museo_visitado).

Fase 3: Normalización Semántica Avanzada (Algorítmica)

Es la fase de mayor complejidad técnica, donde se aplican scripts para interpretar el significado del dato:

1. **Categorización Heurística con Jython/Regex:** Para variables con alta entropía (muy desordenadas), como los tipos de crímenes, se implementan scripts en Python que aplican reglas de Expresiones Regulares en cascada. Esto permite agrupar cientos de variaciones (ej: "Assault", "Batt", "Aggr") en categorías macro estandarizadas, reduciendo la dispersión sin perder información crítica.
2. **Estandarización de Vocabulario:** Aplicación de algoritmos de *Clustering* (agrupamiento) para unificar sinónimos y variaciones ortográficas en variables categóricas (ej: unificación del género en la encuesta).

Fase 4: Estrategia de Reconstrucción Constructiva (Coalescencia)

Aplicada cuando el dato existe, pero está fragmentado o sucio (Caso Direcciones):

1. Limpieza Sintáctica (Parsing): Uso de GREL para "tokenizar" cadenas de texto sucias, eliminando prefijos técnicos redundantes y duplicidades ("PARQUE PARQUE" → "PARQUE").
2. Lógica de Coalescencia: Creación de "Columnas Maestras" a partir de la fusión inteligente de columnas fragmentadas. Se prioriza la construcción de un dato completo (ej: DIRECCION_FINAL) y, una vez validado, se eliminan los fragmentos originales (NOM_VIA, NUM_VIA), garantizando un dataset final limpio y compacto.

4. MEJORAS EN EL CONJUNTO DE DATOS

Tras el análisis profundo de los datasets, y poniendo el foco específicamente en el **Dataset 3 (Encuesta de Visitantes)**, se proponen dos mejoras fundamentales que deben implementarse en la fase de captura (origen) para garantizar la calidad del dato a futuro.

4.1. Granularidad en la Captura de Datos Demográficos (Mejora de Captura)

- **Situación actual:** La encuesta captura la edad del visitante mediante rangos de texto predefinidos (ej: "De 41 a 65 años", "Menos de 18 años").
- **Propuesta:** Modificar el formulario de entrada para solicitar el **Año de Nacimiento** (dato numérico de 4 dígitos).
- **Justificación de Calidad:**
 - **Analítica Avanzada:** Los rangos de texto impiden calcular métricas básicas como la edad media o la desviación estándar.
 - **Flexibilidad:** Si la estrategia de marketing cambia y se requiere segmentar a los "Jóvenes Adultos" (20-29 años), el formato actual lo hace imposible porque los rangos están "quemados" en el dato. Capturar el año exacto permite recalculer la edad y crear cualquier segmentación *a posteriori* sin pérdida de información.

4.2. Desacoplamiento de Metadatos y Datos (Mejora Estructural)

- **Situación actual:** Las cabeceras del dataset contienen las preguntas completas de la encuesta.
- **Propuesta:** Implementar un esquema de base de datos que utilice identificadores de columna técnicos (Q1, Q2 o sexo, visita_museo) y mantener un **Diccionario de Datos** externo que mapee estos códigos a las preguntas reales.
- **Justificación de Calidad:**
 - **Rendimiento:** Reducir la longitud de las claves disminuye drásticamente el tráfico de red al transferir datos en formatos autodescriptivos como JSON.
 - **Mantenibilidad:** Si se corrige una errata en la redacción de la pregunta, no es necesario alterar la estructura física de la base de datos ni romper los procesos ETL que dependen del nombre de la columna. Solo se actualiza el diccionario de metadatos.