

Informe de evaluación LLM - campaign:oe4:v2:20260715011720492

Generado: 2026-07-15T01:54:15.873Z

Validez formal: formal_valid

- Todos los gates formales están satisfechos.

Método

Protocolo aura.oe4.final-evaluation.v2 v2.6.0. Matriz 3 × 3 × 3 = 27 unidades. Dataset synthetic_ground_truth con SHA-256 4e7d358f2141c6463146417a66f1c2312c7c3cdf6a39005780c92b061ff7ac49.

Entorno y modelos

Modelos congelados: hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL, hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL, hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL. Modos de entrada: prompt_libre, smart_sample, recommended. Cada corrida conserva snapshot de hardware, runtime, modelo, inferencia, prompt y hashes.

Matriz de corridas y fallos

Corridas observadas: 27. Intentadas: 27. Completadas: 20. Fallidas: 7. Estados: completed: 20, failed: 7.

Modelo	Entrada	Corridas	Completadas	Fallidas	Alineación GT (F1)	Latencia mediana ms
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	prompt_libre	3	3	0	1.000	46343
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	smart_sample	3	3	0	1.000	57103
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	recommended	3	3	0	1.000	57883
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	3	3	0	1.000	48926
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	smart_sample	3	3	0	1.000	50723
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	recommended	3	3	0	1.000	55725
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	prompt_libre	3	2	1	1.000	29243
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	smart_sample	3	0	3	n/d	n/d
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	recommended	3	0	3	n/d	n/d

Alineación con ground truth

Alineación F1 global con el ground truth: media 1.000, mediana 1.000, mínimo 1.000 y máximo 1.000. Es un control descriptivo frente a un registro conocido, no una prueba de descubrimiento independiente.

Contrato y alucinaciones

Fidelidad de evidencia media: 100.00 %. Anclaje medio: 93.50 %. Las columnas y claims sin soporte se conservan por corrida en campaign.json y se resumen por celda.

Método de calificación automática

Alineación exacta ruleId + columnId + scope contra el ground truth congelado del dataset controlado.

Precisión mide cuántos hallazgos declarados coinciden con el ground truth; recall mide cuántos hallazgos esperados fueron reproducidos; F1 resume ambos. Fiabilidad es la proporción de corridas válidas. Contrato, evidencia, claims sin soporte y eficiencia se calculan de forma determinista a partir de la respuesta, el snapshot, el recibo y las métricas de Ollama.

Latencia, tokens y estabilidad

Latencia total mediana: 51608 ms. Tokens de salida medianos: 3559. Los fallos y reintentos permanecen visibles; no se reemplazan por ceros ni se eliminan.

Scores de apoyo a la decisión

Modelo	Entrada	Alineación GT	Fiabilidad	Contrato	Evidencia	Sin claims no soportados	Eficiencia	Equilibrado
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	prompt_libre	100.0	100.0	100.0	100.0	100.0	63.1	92.6
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	smart_sample	100.0	100.0	0.0	95.8	0.0	51.2	69.2
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	recommended	100.0	100.0	100.0	93.3	0.0	50.5	68.4
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	100.0	100.0	100.0	100.0	59.8	92.0
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	smart_sample	100.0	100.0	0.0	95.8	0.0	57.7	70.5
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	recommended	100.0	100.0	0.0	93.3	0.0	52.5	68.8
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	prompt_libre	100.0	66.7	100.0	100.0	50.0	100.0	78.3
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	smart_sample	n/d	0.0	n/d	n/d	n/d	n/d	0.0
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	recommended	n/d	0.0	n/d	n/d	n/d	n/d	0.0

Índice equilibrado: fiabilidad 35 %, evidencia 25 %, ausencia de claims sin soporte 20 % y eficiencia 20 %. Alineación GT y contrato tienen peso 0 % porque funcionan como control descriptivo y gate de validez. Precisión, recall y F1 describen alineación con un registro de hallazgos conocido y exigido por contrato; por eso no aportan peso al índice equilibrado. El cumplimiento del contrato actúa como condición de validez, no como premio doble. El índice repondera únicamente fiabilidad, evidencia, seguridad frente a claims sin soporte y eficiencia. Es ayuda de decisión para esta campaña, no una afirmación de superioridad universal.

Recomendaciones por objetivo

Objetivo	Modelo	Entrada	Score	Justificación
balanced	hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	prompt_libre	92.6	Mejor equilibrio medido entre fiabilidad, evidencia visible, ausencia de claims sin soporte y velocidad.
diagnostic_quality	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Mayor calidad operativa combinando soporte de evidencia, seguridad frente a claims sin soporte y fiabilidad.
reliability	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Mayor proporción de diagnósticos válidos entre las corridas intentadas.
traceability	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Mayor soporte y anclaje a la evidencia visible del método de entrada.
speed	hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Menor latencia mediana relativa dentro de esta campaña y este hardware.

No existe un campo ni una conclusión de ganador universal. Cada resultado se interpreta dentro de su dimensión.

Amenazas a la validez

- Un único dataset controlado limita la generalización externa.

- Tres repeticiones permiten estadística descriptiva, no afirmaciones causales fuertes.
- El hardware y el runtime local condicionan latencia y throughput.
- El índice equilibrado depende de ponderaciones explícitas y debe interpretarse junto con sus dimensiones.
- La evaluación del Laboratorio cubre diagnóstico LLM; script, HITL y remediación pertenecen al pipeline normal.

Conclusiones acotadas

La campaña campaign:oe4:v2:20260715011720492 satisface los gates de evidencia formal. Los resultados permiten comparar modelos y modos por dimensión, sin afirmar superioridad universal ni corrección automática garantizada.