


Informe diagnóstico de calidad del dato

synthetic_ground_truth.csv

LECTURA EJECUTIVA

Revisión humana antes de publicar o corregir datos

El diagnóstico puede cerrarse: 13 de 15 hallazgo(s) se clasifican como riesgos confirmados y, dentro de ese grupo, 4 son críticos. La salida defendible hoy es informe y trazabilidad; la remediación debe ser una rama revisada.



FECHA	13/07/2026 22:08
FINGERPRINT	40dc4aac
FILAS / COLUMNAS	15 / 9
ESTADO DIAGNÓSTICO	Diagnóstico asistido disponible

Gobernanza del score

Score no modificado por IA. El diagnóstico contextualiza evidencia, no recalcula la calificación.

DIAGNÓSTICO ESTRUCTURADO

Resumen ejecutivo

Revisión humana antes de publicar o corregir datos

- El diagnóstico puede cerrarse: 13 de 15 hallazgo(s) se clasifican como riesgos confirmados y, dentro de ese grupo, 4 son críticos. La salida defendible hoy es informe y trazabilidad; la remediación debe ser una rama revisada.

0/100

Score base
No modificado por IA

13

Riesgos confirmados
Incluye 4 críticos

15

Hallazgos

15 / 9

Filas / columnas

Diagnóstico estructurado construido sobre 15 hallazgo(s) determinista(s), score base 0/100. Observacion principal: 1 fila idéntica detectada en el conjunto de datos completo.

Trazabilidad de ejecución LLM

Método	recommended
Proveedor / modelo	Ollama / hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL
Prompt hash	d456c25581cddc11011a13b3ea46a42092ae6b750c95141bd306d3f8e98dfec0
Input hash	d6c0c2fc53ede143ddbb15d3f6366801d8b593b80000e4f085af2d4e5afd5e5e
Receipt hash	9fd45fe7ad8acfe542f2fa6dc341345b85b3182556faa6e3b5567870a2988928
Evidence envelope	env:84f35ac4e828fafaeea2af5469a405700881c1082ed31d221164bfcf54d480b0
Fecha	2026-07-14T03:08:33.288Z
Validación	valid

Riesgos principales

- Datos Sensibles (PII) en ip_acceso: 15 registro(s), 100% afectado. Patrones de Tarjeta de Crédito o IP detectados.
- Filas Duplicadas: 1 registro(s), 6.67% afectado. Se encontraron 1 filas idénticas que afectan la integridad estructural.
- Formato Email Inválido en email: 1 registro(s), 6.67% afectado. Cadenas sin estructura de correo.
- Negativos Imposibles en salario: 1 registro(s), 6.67% afectado. Valores negativos en campo lógico (Edad, Precio).
- Formatos de Fecha Mixtos en fecha_ingreso: 1 registro(s), 6.67% afectado. La columna mezcla fechas ISO con fechas escritas mediante barras; el orden día/mes debe confirmarse antes de convertir.

Alcance de esta lectura

- El score pertenece al motor determinista y no fue modificado por el modelo.
- La interpretación asistida no sustituye la evidencia ni autoriza correcciones automáticas.
- No hay evidencia visible de las filas duplicadas específicas.
- No hay evidencia visible de los valores nulos específicos en nombre, edad, email y estado.

EVIDENCIA DETERMINISTA

Perfil técnico base



Severidad: críticos: 4 · advertencias: 11

Categoría: Integridad y Estructura: 5 · Higiene de Texto: 4 · Validez y Lógica de Negocio: 5 · Semántica y Seguridad: 1

VECTORES PDF

Gráficos estadísticos reproducibles

Vectores PDF reproducibles derivados del reporte, sin imágenes externas.

Problemas Críticos por Severidad

Visualizar los problemas críticos para priorizar el remedio.



Distribución de Problemas por Categoría

Distribución de problemas por categoría para entender el impacto.



Columnas con Nulos

Identificar columnas con más nulos para limpieza.

6.67	edad	0.00%
6.67	email	0.00%
6.67	estado	0.00%
6.67	nombre	0.00%

Problemas con Mayor Impacto en Filas

Identificar los problemas que afectan más filas.

100		0.00%
6.67		0.00%
6.67		0.00%
6.67		0.00%
13.33		0.00%
6.67		0.00%
6.67		0.00%
6.67		0.00%

EVIDENCIA Y ALCANCE

Hallazgos confirmados principales

Se presentan 6 de 13 hallazgos confirmados, priorizados por severidad. El detalle completo permanece en JSON y CSV; los falsos positivos documentados no aparecen aquí.

Hallazgo	Sev.	Columnas	Evidencia	Interpretación	Rev. humana
Datos Sensibles (PII) en ip_acceso	Crítica	ip_acceso	15 registro(s), 100% afectado. Patrones de Tarjeta de Crédito o IP detectados.	Lectura asistida: 15 valores detectados como PII (patrones de tarjeta/IP). Recomendación: Revisar políticas de seguridad y anonimizar datos sensibles.	Sí
Filas Duplicadas	Crítica	Dataset	1 registro(s), 6.67% afectado. Se encontraron 1 filas idénticas que afectan la integridad estructural.	Lectura asistida: 1 fila idéntica detectada en el conjunto de datos completo. Recomendación: Considerar eliminación de filas duplicadas exactas par...	Sí
Formato Email Inválido en email	Crítica	email	1 registro(s), 6.67% afectado. Cadenas sin estructura de correo.	Lectura asistida: Valor 'sha256:...' detectado como email inválido. Recomendación: Revisar si el hash es intencional o debe ser reemplazado por ema...	Sí
Negativos Imposibles en salario	Crítica	salario	1 registro(s), 6.67% afectado. Valores negativos en campo lógico (Edad, Precio).	Lectura asistida: Valor -1500 detectado como negativo imposible. Recomendación: Revisar si el valor es error de entrada o lógica de negocio invertida.	Sí
Outliers Extremos (IQR 3×) en salario	Advertencia	salario	2 registro(s), 13.33% afectado. Valores desviados > 3× del rango intercuartílico.	Lectura asistida: Valores -1500 y '9***9' detectados como outliers extremos. Recomendación: Revisar si los valores son errores de entrada o datos a...	Sí
Placeholders Tóxicos en edad	Advertencia	edad	1 registro(s), 6.67% afectado. Valores como "n/a", "null" o "999" detectados.	Lectura asistida: Valor 'N/A' detectado como placeholder tóxico. Recomendación: Revisar si el placeholder debe ser reemplazado por nulo o valor est...	Sí

DECISIÓN HUMANA

Revisión antes de corregir

Estos casos son posibles falsos positivos o dependen del contexto. No modifican el score y no deben corregirse automáticamente.

- id: alta cardinalidad con apariencia de identificador o descriptor. id tiene 14 valores únicos; puede ser identificador, nombre, ticket, código o descriptor granular. Decisión: revisar humanamente; no modifica el score.
- nombre: alta cardinalidad con apariencia de identificador o descriptor. nombre tiene 13 valores únicos; puede ser identificador, nombre, ticket, código o descriptor granular. Decisión: revisar humanamente; no modifica el score.

Plan de acción

- Media prioridad - Inspeccionar - Inspeccionar patrón de ausencia antes de imputar - Los nulos pueden indicar ausencia informativa, sesgo de captura o campos no aplicables. No deben imputarse sin revisar el contexto.
- Media prioridad - No corregir automáticamente - Revisar contexto de outliers antes de recortar o capar - Valores extremos pueden ser errores o eventos válidos del dominio. La revisión humana debe preceder cualquier transformación.
- Alta prioridad - No corregir automáticamente - Aplicar política de privacidad o anonimización según el objetivo - Los campos con posible PII requieren decisión de uso, minimización o anonimización antes de compartir o publicar evidencia.
- Baja prioridad - Generar script opcional - Generar script solo como rama opcional de remediación - El reporte principal no requiere script. Si se decide remediar, el script debe quedar como anexo revisado humanamente.

Remediación opcional: el informe puede cerrarse sin script; cualquier corrección se realiza sobre una copia y con revisión humana.

Certificado de trazabilidad

Run ID	audit-1783997685425
Report ID	diag-report-a278ff8f
SHA-256 dataset	4e7d358f2141c6463146417a66f1c2312c7c3cdf6a39005780c92b061ff7ac49
SHA-256 reporte	e305a7236b2fd4984b9a83d4d087229f63cee6dcdfa3273050db6e84112e872f
Receipt hash	9fd45fe7ad8acfe542f2fa6dc341345b85b3182556faa6e3b5567870a2988928
Modelo solicitado	hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL
Modelo observado	hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL
Método	recommended

SCRIPT APROBADO

Anexo: script Python

Script incluido como anexo operativo aprobado por revisión humana. El PDF no ejecuta el código; conserva la trazabilidad para revisión, reproducción y auditoría.

limpieza_dataset.pyPython - aprobado

```
001 # AURA diagnosis input mode: recommended
002 # AURA input receipt: 9fd45fe7ad8acfe542f2fa6dc341345b85b3182556faa6e3b5567870a2988928
003 # AURA prompt hash: d456c25581cddc11011a13b3ea46a42092ae6b750c95141bd306d3f8e98dfec0
004 # AURA input hash: d6c0c2fc53ede143ddbb15d3f6366801d8b593b80000e4f085af2d4e5afd5e5e
005 # AURA evidence envelope: env:84f35ac4e828fafaaea2af5469a405700881c1082ed31d221164bfcf54d480b0
006
007 import pandas as pd
008 import numpy as np
009
010 _c = {
011     "col:66c132b9f764eca1": "id",
012     "col:c48ed5501a3f61e9": "nombre",
013     "col:14a06a875d2805a1": "edad",
014     "col:3ccf050c2a6ae5c6": "salario",
015     "col:534000c8bf517b29": "email",
016     "col:715d2723c97715b7": "departamento",
017     "col:623e34a359a89dd3": "fecha_ingreso",
018     "col:f9b45ca6934a8296": "estado",
019     "col:e7b2c5a4df357066": "ip_acceso"
020 }
021
022 def clean_dataset(df):
023     df_clean = df.copy()
024     df_clean = df_clean.drop_duplicates(keep="first").copy()
025     df_clean[_c["col:14a06a875d2805a1"]] = df_clean[_c["col:14a06a875d2805a1"]].replace(["", "n/a",
"N/A", "na", "NA", "null", "NULL", "none", "None", "?", "-", "--", "...", "NaN", "NAN", "nan",
"N/a"], np.nan)
026     df_clean[_c["col:534000c8bf517b29"]] = df_clean[_c["col:534000c8bf517b29"]].replace(["", "n/a",
"N/A", "na", "NA", "null", "NULL", "none", "None", "?", "-", "--", "...", "NaN", "NAN", "nan",
"N/a"], np.nan)
027     df_clean[_c["col:f9b45ca6934a8296"]] = df_clean[_c["col:f9b45ca6934a8296"]].replace(["", "n/a",
"N/A", "na", "NA", "null", "NULL", "none", "None", "?", "-", "--", "...", "NaN", "NAN", "nan",
"N/a"], np.nan)
028     return df_clean
```