


Informe diagnóstico de calidad del dato

synthetic_ground_truth.csv

LECTURA EJECUTIVA

Revisión humana antes de publicar o corregir datos

El diagnóstico puede cerrarse: 13 de 15 hallazgo(s) se clasifican como riesgos confirmados y, dentro de ese grupo, 4 son críticos. La salida defendible hoy es informe y trazabilidad; la remediación debe ser una rama revisada.



FECHA	14/07/2026 08:12
FINGERPRINT	40dc4aac
FILAS / COLUMNAS	15 / 9
ESTADO DIAGNÓSTICO	Diagnóstico asistido disponible

Gobernanza del score

Score no modificado por IA. El diagnóstico contextualiza evidencia, no recalcula la calificación.

DIAGNÓSTICO ESTRUCTURADO

Resumen ejecutivo

Revisión humana antes de publicar o corregir datos

- El diagnóstico puede cerrarse: 13 de 15 hallazgo(s) se clasifican como riesgos confirmados y, dentro de ese grupo, 4 son críticos. La salida defendible hoy es informe y trazabilidad; la remediación debe ser una rama revisada.

0/100	13	15	15 / 9
Score base	Riesgos confirmados	Hallazgos	Filas / columnas
No modificado por IA	Incluye 4 críticos		

Diagnóstico estructurado construido sobre 15 hallazgo(s) determinista(s), score base 0/100. Observacion principal: Se encontraron 1 filas idénticas que afectan la integridad estructural.

Trazabilidad de ejecución LLM

Método	smart_sample
Proveedor / modelo	Ollama / hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL
Prompt hash	3eb2547b9e931a05ac15d3fe4f1905f530cf3fcf87f01270d0711c096e844e9c
Input hash	a1619bb68e3d51f9a7b468e4b87f736b34cc10f4ff74236ba64954555afccb85
Receipt hash	0592744ddc56845d5cb35adaf628114cd019ccdc50b00bddaed40b8cbb457f9c
Evidence envelope	env: 84f35ac4e828fafaaea2af5469a405700881c1082ed31d221164bfcf54d480b0
Fecha	2026-07-14T13:12:32.615Z
Validación	valid

Riesgos principales

- Datos Sensibles (PII) en ip_acceso: 15 registro(s), 100% afectado. Patrones de Tarjeta de Crédito o IP detectados.
- Filas Duplicadas: 1 registro(s), 6.67% afectado. Se encontraron 1 filas idénticas que afectan la integridad estructural.
- Formato Email Inválido en email: 1 registro(s), 6.67% afectado. Cadenas sin estructura de correo.
- Negativos Imposibles en salario: 1 registro(s), 6.67% afectado. Valores negativos en campo lógico (Edad, Precio).
- Formatos de Fecha Mixtos en fecha_ingreso: 1 registro(s), 6.67% afectado. La columna mezcla fechas ISO con fechas escritas mediante barras; el orden día/mes debe confirmarse antes de convertir.

Alcance de esta lectura

- El score pertenece al motor determinista y no fue modificado por el modelo.
- La interpretación asistida no sustituye la evidencia ni autoriza correcciones automáticas.
- The diagnosis relies on sample data, and the findings may not be representative of the entire dataset.
- Specific remediation steps are descriptive; actual implementation requires domain knowledge.

EVIDENCIA DETERMINISTA

Perfil técnico base

,	1	4	11
Delimitador	Duplicados	Críticos	Advertencias

Severidad: críticos: 4 · advertencias: 11

Categoría: Integridad y Estructura: 5 · Higiene de Texto: 4 · Validez y Lógica de Negocio: 5 · Semántica y Seguridad: 1


VECTORES PDF

Gráficos estadísticos reproducibles

Vectores PDF reproducibles derivados del reporte, sin imágenes externas.

Frequency of Data Quality Issues by Issue ID

A bar chart is suitable to visualize the frequency and impact of each identified data quality issue across the dataset.



EVIDENCIA Y ALCANCE

Hallazgos confirmados principales

Se presentan 6 de 13 hallazgos confirmados, priorizados por severidad. El detalle completo permanece en JSON y CSV; los falsos positivos documentados no aparecen aquí.

Hallazgo	Sev.	Columnas	Evidencia	Interpretación	Rev. humana
Datos Sensibles (PII) en ip_acceso	Crítica	ip_acceso	15 registro(s), 100% afectado. Patrones de Tarjeta de Crédito o IP detectados.	Lectura asistida: Se detectaron patrones de PII (IP) en la columna 'ip_acceso'. Recomendación: Implementar medidas de anonimización o enmascaramien...	Sí
Filas Duplicadas	Crítica	Dataset	1 registro(s), 6.67% afectado. Se encontraron 1 filas idénticas que afectan la integridad estructural.	Lectura asistida: Se encontraron 1 filas idénticas que afectan la integridad estructural. Recomendación: Considerar eliminar las filas duplicadas p...	Sí
Formato Email Inválido en email	Crítica	email	1 registro(s), 6.67% afectado. Cadenas sin estructura de correo.	Lectura asistida: Se detectaron cadenas en la columna 'email' que no cumplen con el formato de correo válido. Recomendación: Validar y corregir los...	Sí
Negativos Imposibles en salario	Crítica	salario	1 registro(s), 6.67% afectado. Valores negativos en campo lógico (Edad, Precio).	Lectura asistida: Se encontraron valores negativos en la columna 'salario'. Recomendación: Investigar los registros con salario negativo, ya que es...	Sí
Outliers Extremos (IQR 3×) en salario	Advertencia	salario	2 registro(s), 13.33% afectado. Valores desviados > 3× del rango intercuartílico.	Lectura asistida: Se detectaron valores extremos en la columna 'salario' (ej. -1500, 9***9). Recomendación: Revisar los datos atípicos para determi...	Sí
Placeholders Tóxicos en edad	Advertencia	edad	1 registro(s), 6.67% afectado. Valores como "n/a", "null" o "999" detectados.	Lectura asistida: Se detectaron valores como "N/A" en la columna 'edad'. Recomendación: Considerar estandarizar los placeholders tóxicos a un valor...	Sí

DECISIÓN HUMANA

Revisión antes de corregir

Estos casos son posibles falsos positivos o dependen del contexto. No modifican el score y no deben corregirse automáticamente.

- id: alta cardinalidad con apariencia de identificador o descriptor. id tiene 14 valores únicos; puede ser identificador, nombre, ticket, código o descriptor granular. Decisión: revisar humanamente; no modifica el score.
- nombre: alta cardinalidad con apariencia de identificador o descriptor. nombre tiene 13 valores únicos; puede ser identificador, nombre, ticket, código o descriptor granular. Decisión: revisar humanamente; no modifica el score.

Plan de acción

- Media prioridad - Inspeccionar - Inspeccionar patrón de ausencia antes de imputar - Los nulos pueden indicar ausencia informativa, sesgo de captura o campos no aplicables. No deben imputarse sin revisar el contexto.
- Media prioridad - No corregir automáticamente - Revisar contexto de outliers antes de recortar o capar - Valores extremos pueden ser errores o eventos válidos del dominio. La revisión humana debe preceder cualquier transformación.
- Alta prioridad - No corregir automáticamente - Aplicar política de privacidad o anonimización según el objetivo - Los campos con posible PII requieren decisión de uso, minimización o anonimización antes de compartir o publicar evidencia.
- Baja prioridad - Generar script opcional - Generar script solo como rama opcional de remediación - El reporte principal no requiere script. Si se decide remediar, el script debe quedar como anexo revisado humanamente.

Remediación opcional: el informe puede cerrarse sin script; cualquier corrección se realiza sobre una copia y con revisión humana.

Certificado de trazabilidad

Run ID	audit-1784034289352
Report ID	diag-report-d76dbe5e
SHA-256 dataset	4e7d358f2141c6463146417a66f1c2312c7c3cdf6a39005780c92b061ff7ac49
SHA-256 reporte	154bf6facb506d2da44aa81ba24f5ff9cabfb687d60a25f10ecd529f474076e9
Receipt hash	0592744ddc56845d5cb35adaf628114cd019ccdc50b00bddaed40b8cbb457f9c
Modelo solicitado	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL
Modelo observado	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL
Método	smart_sample