

Informe de evaluación LLM - campaign:oe4:v2:20260714203639584

Generado: 2026-07-14T22:28:55.117Z

Validez formal: formal_valid

- Todos los gates formales están satisfechos.

Método

Protocolo aura.oe4.final-evaluation.v2 v2.5.0. Matriz 3 × 3 × 3 = 27 unidades. Dataset synthetic_ground_truth con SHA-256 4e7d358f2141c6463146417a66f1c2312c7c3cdf6a39005780c92b061ff7ac49.

Entorno y modelos

Modelos congelados: hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL, hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL, hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL. Modos de entrada: prompt_libre, smart_sample, recommended. Cada corrida conserva snapshot de hardware, runtime, modelo, inferencia, prompt y hashes.

Matriz de corridas y fallos

Corridas observadas: 27. Intentadas: 27. Completadas: 19. Fallidas: 8. Estados: awaiting_human: 19, failed: 8.

Modelo	Entrada	Corridas	Completadas	Fallidas	F1 medio	Latencia mediana ms
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	prompt_libre	3	3	0	1.000	49606
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	smart_sample	3	3	0	1.000	57523
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	recommended	3	3	0	1.000	56517
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	3	3	0	1.000	49415
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	smart_sample	3	3	0	1.000	51376
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	recommended	3	3	0	1.000	53929
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	prompt_libre	3	1	2	1.000	27077
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	smart_sample	3	0	3	n/d	n/d
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	recommended	3	0	3	n/d	n/d

Calidad diagnóstica

F1 primario global: media 1.000, mediana 1.000, mínimo 1.000 y máximo 1.000. La cobertura del motor y los descubrimientos extendidos permanecen separados del F1 primario.

Contrato y alucinaciones

Fidelidad de evidencia media: 100.00 %. Anclaje medio: 93.16 %. Las columnas y claims sin soporte se conservan por corrida en campaign.json y se resumen por celda.

Método de calificación automática

Coincidencia exacta ruleId + columnName + scope contra el oráculo congelado del dataset controlado.

Precisión mide cuántos hallazgos declarados son correctos; recall mide cuántos hallazgos esperados fueron encontrados; F1 es su media armónica. Fiabilidad es la proporción de corridas válidas. Contrato, evidencia, alucinaciones y eficiencia se calculan de forma determinista a partir de la respuesta, el snapshot, el recibo y las métricas de Ollama.

Latencia, tokens y estabilidad

Latencia total mediana: 51376 ms. Tokens de salida medianos: 3568. Los fallos y reintentos permanecen visibles; no se reemplazan por ceros ni se eliminan.

Scores de apoyo a la decisión

Modelo	Entrada	Exactitud	Fiabilidad	Contrato	Evidencia	Sin alucinaciones	Eficiencia	Equilibrado
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	prompt_libre	100.0	100.0	100.0	100.0	66.7	54.6	94.4
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	smart_sample	100.0	100.0	0.0	95.8	0.0	47.1	71.7
hf.co/unsloth/Qwen3.5-4B-GGUF:UD-Q4_K_XL	recommended	100.0	100.0	100.0	93.3	0.0	47.9	86.4
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	100.0	100.0	100.0	100.0	100.0	54.8
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	smart_sample	100.0	100.0	0.0	95.8	0.0	52.7	72.0
hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	recommended	100.0	100.0	33.3	93.3	0.0	50.2	76.5
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	prompt_libre	100.0	33.3	100.0	100.0	100.0	100.0	86.7
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	smart_sample	n/d	0.0	n/d	n/d	n/d	n/d	0.0
hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	recommended	n/d	0.0	n/d	n/d	n/d	n/d	0.0

Índice equilibrado: exactitud 35 %, fiabilidad 20 %, contrato 15 %, evidencia 15 %, ausencia de alucinaciones 10 % y eficiencia 5 %. El índice equilibrado repondera únicamente las dimensiones medibles. Es ayuda de decisión para esta campaña, no una afirmación de superioridad universal.

Recomendaciones por objetivo

Objetivo	Modelo	Entrada	Score	Justificación
balanced	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	97.7	Mejor equilibrio entre calidad, estabilidad, contrato, evidencia, seguridad y velocidad.
diagnostic_quality	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Mayor F1 medio frente al oráculo controlado.
reliability	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Mayor proporción de diagnósticos válidos entre las corridas intentadas.
traceability	hf.co/unsloth/gemma-4-E4B-it-qat-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Mayor soporte y anclaje a la evidencia visible del método de entrada.
speed	hf.co/unsloth/SmolLM3-3B-GGUF:UD-Q4_K_XL	prompt_libre	100.0	Menor latencia mediana relativa dentro de esta campaña y este hardware.

No existe un campo ni una conclusión de ganador universal. Cada resultado se interpreta dentro de su dimensión.

Amenazas a la validez

- Un único dataset controlado limita la generalización externa.
- Tres repeticiones permiten estadística descriptiva, no afirmaciones causales fuertes.
- El hardware y el runtime local condicionan latencia y throughput.

- El índice equilibrado depende de ponderaciones explícitas y debe interpretarse junto con sus dimensiones.
- La evaluación del Laboratorio cubre diagnóstico LLM; script, HITL y remediación pertenecen al pipeline normal.

Conclusiones acotadas

La campaña campaign:oe4:v2:20260714203639584 satisface los gates de evidencia formal. Los resultados permiten comparar modelos y modos por dimensión, sin afirmar superioridad universal ni corrección automática garantizada.